



Previsão de risco de inadimplência

REPORTE EXECUTIVO |

Prever o risco de inadimplência

Desafio de Negócio

Identificar padrões associados ao risco de crédito para apoiar o processo de análise de decisão.


36.457

REGISTROS ANALISADOS

11,8%

MAUS PAGADORES

A base apresenta um forte desbalanceamento. Por isso, não basta o modelo acertar a maioria dos casos: ele também precisa identificar os maus pagadores.



Distribuição da Base de Dados

Da base de dados ao modelo



Dados

- 36.457 registros
- Variáveis demográficas, financeiras e sociais
- Tratamento de informações ausentes

Processamento

- One-Hot Encoding
- Binários (0/1)
- Remoção de variáveis não utilizadas

Treino/Teste

- Divisão 80/20
- Stratified Split
- Padronização de Escalas

Modelagem

- 6 algoritmos testados

Avaliação

- F1-Score
- ROC-AUC
- Recall x Precision
- Custo de erro

Log. Reg

KNN

SVM

Decision Tree

Random Forest

O risco não está concentrado em um único perfil

Não encontramos uma regra simples capaz de definir o inadimplente. O comportamento de pagamento está associado à combinação de múltiplas dimensões.

- Variáveis apresentam diferentes padrões, mas não isoladamente.
- Resultados representam associações, não causalidade.
- O modelo de Machine Learning foi utilizado para combinar essas informações e identificar padrões de risco.



Combinação de características múltiplas



Identificação de padrões de risco

Random Forest: melhor desempenho relativo

Modelo	Acerto Geral Accuracy	Confiabilidade Precision	Identificação Recall	Equilíbrio F1-score	Diferenciação ROC-AUC
Regressão Logística	88,27%	100,00%	0,35%	0,70%	55,02%
Reg. Log. (Balanced)	57,97%	13,66%	48,37%	21,31%	54,97%
KNN	87,63%	44,53%	20,86%	28,41%	73,13%
SVM	88,26%	55,56%	1,17%	2,28%	65,24%
Árvore de Decisão	88,11%	49,17%	31,24%	38,20%	75,67%
Random Forest	88,85%	54,25%	33,45%	41,38%	80,46%

A Regressão Logística Balanceada obteve maior Recall (48,37%), mas apresentou Precision muito baixa (13,66%), o que pode gerar **alarmes falsos**. A escolha depende do equilíbrio entre os tipos de erro.

RECALL (33,45%)

Identificação

O modelo capturou aproximadamente 1/3 dos maus pagadores reais na base de teste.

PRECISION (54,25%)

Confiabilidade

Dos clientes sinalizados como risco, 54% realmente eram maus pagadores.


ROC-AUC (80,46%)

Diferenciação

Melhor capacidade de distinguir entre bons e maus pagadores entre os modelos.

Implicações para a decisão de crédito

O QUE O MODELO INDICA



As três primeiras variáveis somam aproximadamente 54,6% da importância observada no Random Forest. Essa medida representa contribuição para as decisões do modelo, não causalidade.

CONDIÇÕES PARA EVOLUIR

- ✓ Validar o modelo com dados mais recentes e representativos do cenário real.
- ✓ Definir qual erro é mais crítico para o negócio: deixar passar um mau pagador ou sinalizar um bom pagador.
- ✓ Ajustar o ponto de decisão conforme esse equilíbrio e avaliar novas variáveis.

Potencial para apoiar a análise de crédito — ainda requer validação e otimização antes de uma aplicação real.